

Proje Gelişim Raporu

1. Proje Amacı

Bu projede amaç, haber metinlerinden özgün özetler üretebilen bir doğal dil işleme (NLP) sistemi geliştirmektir. Transformer tabanlı bir mimari (özellikle T5-small) kullanılarak, CNN/DailyMail veri seti üzerinde model eğitilmiş ve eğitilen model daha sonra test verileri üzerinde değerlendirilmiştir.

2. Kullanılan Veri Seti

- Veri Seti: CNN/DailyMail
- Alanlar: `article` (giriş metni) ve `highlights` (referans özet)
- Eğitim verisi olarak ilk 1000 örnek (`cnn_dailymail_sample.json`), test verisi olarak sonraki 200 örnek (`cnn_dailymail_test.json`) seçilmiştir.

3. Ön İşleme

- Metinler küçük harfe çevrilmiş ve temizlenmiştir.
- Tokenizer: `T5Tokenizer`
- Giriş metni "summarize: " formatında hazırlanmıştır.
- Uzunluk sınırlamaları: `max_length=128`

4. Model Eğitimi

- Kullanılan model: `t5-small`
- Eğitim süreci `scripts/train.py` dosyası ile yürütülmüştür.
- Eğitim parametreleri `outputs/hyperparameters.json` dosyasında kayıtlıdır.
- Eğitim logları `train_log.txt` dosyasında tutulmuştur.

5. Tahmin Fonksiyonu

- `scripts/predict.py` içinde tanımlanmıştır.
- Örnek metinlerden özet üretimi yapılmaktadır.
- Tokenizer ve model yalnızca yerel dosyalardan yüklenmektedir (`local_files_only=True`).

6. Değerlendirme (ROUGE)

- ROUGE metrikleri ile modelin özetleme başarımı test edilmiştir.
- Kullanılan metrikler: ROUGE-1, ROUGE-2, ROUGE-L, ROUGE-Lsum
- Değerlendirme kodu: scripts/test.py

Örnek Çıktı:

```
"index": 9,
```

```
"article": "(CNN)For the first time in eight years, a TV legend returned to doing what he does best. Contestants told to \"come on down!\" on the April 1 edition of \"The Price Is Right\" encountered not host Drew Carey but another familiar face in charge of the proceedings. Instead, there was Bob Barker, who hosted the TV game show for 35 years before stepping down in 2007. Looking spry at 91, Barker handled the first price-guessing game of the show, the classic \"Lucky Seven,\" before turning hosting duties over to Carey, who finished up. Despite being away from the show for most of the past eight years, Barker didn't seem to miss a beat.",
```

```
"reference_summary": "Bob Barker returned to host \"The Price Is Right\" on Wednesday .\nBarker, 91, had retired as host in 2007 .",
```

```
"predicted_summary": "bob barker hosted the tv game show for 35 years before stepping down in 2007."
}
```

ROUGE Sonuçları (ilk 10 örnek için):

- ROUGE-1: **0.3597**
- ROUGE-2: **0.1183**
- ROUGE-L: **0.2617**
- ROUGE-Lsum: **0.3049**

Model, 10.000 örnekle yeniden eğitildikten sonra ROUGE-1: **0.3613**, ROUGE-2: **0.1498**, ROUGE-L: **0.2666** ve ROUGE-Lsum: **0.2987** skorlarına ulaşarak bilgi kapsama açısından orta düzeyde başarı gösterse de, dil bütünlüğü ve yapı açısından hâlâ gelişime açıktır.

Bu sonuçlar, modelin özellikle kelime düzeyinde (ROUGE-1) makul başarımlar gösterdiğini, fakat iki kelimelik ardışık eşleşmelerde (ROUGE-2) daha sınırlı başarıya ulaştığını göstermektedir. Modelin genel yapıyı yakalayabilme (ROUGE-L ve Lsum) yeteneği tatmin edici düzeydedir.

7. Dosya Yapısı Açıklaması

```
ep5-1707/
├── data/                                # Örnek verilerin bulunduğu klasör
│   ├── cnn_dailymail_sample.json        # Eğitim için kullanılan ilk 1000
örnek
│   ├── cnn_dailymail_test.json          # Modelin testinde kullanılan 200
örnek
│   └── cnn_dailymail_validation.json     # İsteğe bağlı doğrulama verileri
(validation)
├── models/
│   └── t5-small-summary/                # İndirilen ve eğitilen T5 model
klasörü
│   ├── added_tokens.json                # Eklenen özel token'ların tanımı
│   └── config.json                      # Model mimarisi ve yapılandırma
ayarları
├── generation_config.json               # Özetleme sırasında kullanılan
parametreler
│   ├── model.safetensors                # Eğitilmiş modelin ağırlıkları
│   ├── special_tokens_map.json          # Özel tokenların görev tanımları
([PAD], [EOS] vb.)
│   └── spiece.model                     # Tokenizer için SentencePiece
modeli
│   └── tokenizer_config.json            # Tokenizer davranış ayarları
├── outputs/                             # Eğitim ve test sonrası
oluşturulan çıktılar
│   ├── hyperparameters.json             # Eğitimde kullanılan
parametrelerin kayıt dosyası
│   ├── test_results.json                # ROUGE metriklerinin ve örnek
özetlerin kayıtlı hali
│   ├── tokenized_data.npz              # Tokenize edilmiş input ve target
verileri
│   └── train_log.txt                    # Eğitim sürecine ait loglar
├── scripts/                             # Tüm kod dosyalarının bulunduğu
klasör
│   ├── predict.py                       # Model ile özet üretimi yapan
fonksiyon
│   ├── preprocessing.py                 # Veriyi tokenize eden ve .npz
olarak kaydeden dosya
│   └── test.py                           # ROUGE skorları ile modelin
başarımını test eden dosya
│   ├── train.py                         # Huggingface Trainer API ile
modeli eğiten dosya
│   └── test_training_args.py            # Eğitim parametrelerinin
uyumluluğunu test eden yardımcı dosya
├── main.py                              # FastAPI arayüzü ile özetleme
servisi sunan ana dosya
├── README.md                            # Proje ile ilgili genel
açıklamaların yer aldığı tanıtım dosyası
```

└─ .gitignore
tutulacak dosyalar

Git versiyon kontrolünde hariç

8. Sonuç ve Öneriler

Model, sınırlı veri ile eğitilmiş olmasına rağmen genel olarak tutarlı ve anlamlı özetler üretebilmektedir. ROUGE-1 ve ROUGE-Lsum skorları bu durumu desteklemektedir. Modelin daha büyük veri ile yeniden eğitilmesi ve beam search gibi parametrelerin optimize edilmesi, özet kalitesini artıracaktır.

BINARY SISTERS

İLAYDA ARZU AKKUŞ - ECE SUDE GÜNERHAN

GITHUB: <https://github.com/iarzuakkus/GYK-NLP-Odev/tree/main/ep5-1707>