

Proje Gelişim Raporu

1. Proje Amacı

Bu projede amaç, haber metinlerinden özgün özetler üretebilen bir doğal dil işleme (NLP) sistemi geliştirmektir. Transformer tabanlı bir mimari (T5-small) kullanılarak, CNN/DailyMail veri seti üzerinde model eğitilmiş ve test verileri üzerinde değerlendirilmiştir.

2. Kullanılan Veri Seti

- Veri Seti: CNN/DailyMail
- Alanlar: `article` (giriş metni) ve `highlights` (referans özet)
- Eğitim verisi: `cnn_dailymail_sample.json` (1000 örnek)
- Test verisi: `cnn_dailymail_test.json` (200 örnek)
- Doğrulama verisi: `cnn_dailymail_validation.json`

Not: 1000 verilik ilk versiyon `t5-small-summary-v1` klasöründe; 10.000 verilik geliştirilmiş versiyon `t5-small-summary` klasöründe tutulmuş, farklar çıktı dosyalarında ("`_m2`") belirtilmiştir.

3. Ön İşleme

- Metinler küçük harfe çevrilmiş ve temizlenmiştir.
- Tokenizer: `T5Tokenizer`
- Giriş metni: `summarize:` formatında hazırlanmıştır.
- Maksimum uzunluk: `max_length=128`
- Tokenize veriler: `tokenized_train_data.npz`, `tokenized_validation_data.npz`, `tokenized_data_1k.npz`

4. Model Eğitimi

- Model: `t5-small`
- Kod: `scripts/train.py`
- Parametreler: `outputs/hyperparameters_1k.json` ve `outputs/hyperparameters.json`
- Model dosyası: `models/t5-small-summary/` ve `t5-small-summary-v1/`

5. Tahmin Fonksiyonu

- Dosya: `scripts/predict.py`
- Amaç: Giriş metinlerinden özet üretimi
- Yalnızca yerel dosyalar kullanılmıştır (`local_files_only=True`)

6. Değerlendirme (ROUGE)

- Kullanılan metrikler: ROUGE-1, ROUGE-2, ROUGE-L, ROUGE-Lsum
- Kod: scripts/test.py
- Test sonuçları: outputs/test_results.json ve test_results_m2.json

Örnek Çıktı:

```
{  
  
  "index": 9,  
  
  "article": "(CNN)For the first time in eight years, a TV legend  
returned to doing what he does best. Contestants told to \"come on down!\"  
on the April 1 edition of \"The Price Is Right\" encountered not host Drew  
Carey but another familiar face in charge of the proceedings. Instead,  
there was Bob Barker, who hosted the TV game show for 35 years before  
stepping down in 2007. Looking spry at 91, Barker handled the first price-  
guessing game of the show, the classic \"Lucky Seven,\" before turning  
hosting duties over to Carey, who finished up. Despite being away from the  
show for most of the past eight years, Barker didn't seem to miss a beat.",  
  
  "reference_summary": "Bob Barker returned to host \"The Price Is  
Right\" on Wednesday .\nBarker, 91, had retired as host in 2007 .",  
  
  "predicted_summary": "bob barker hosted the tv game show for 35 years  
before stepping down in 2007 he handled the first price-guessing game of  
the show, the classic \"lucky seven\""  
  
}
```

ROUGE Sonuçları:

1K veri ile eğitilmiş model (outputs/test_results.json):

- ROUGE-1: 0.3597
- ROUGE-2: 0.1183
- ROUGE-L: 0.2617
- ROUGE-Lsum: 0.3049

10K veri ile eğitilmiş model (outputs/test_results_m2.json):

- ROUGE-1: 0.3613
- ROUGE-2: 0.1498
- ROUGE-L: 0.2666
- ROUGE-Lsum: 0.2987

İlk modele göre 10K veri ile eğitilen model kelime çiftleri ve yapısal benzerlikte daha iyi performans göstermiştir.

7. Dosya Yapısı

```
ep5-1707/
├── data/
│   ├── cnn_dailymail_sample.json
│   └── cnn_dailymail_test.json
├── verisi
│   ├── cnn_dailymail_validation.json
│   └── models/
│       ├── t5-small-summary/
│       └── t5-small-summary-v1/
├── dosyaları
│   ├── t5-small-summary-v1/
├── versiyonu
│   ├── outputs/
│   │   ├── hyperparameters_1k.json
│   │   ├── hyperparameters.json
│   │   ├── test_results.json
│   │   ├── test_results_m2.json
│   │   ├── tokenized_data_1k.npz
│   │   ├── tokenized_train_data.npz
│   │   ├── tokenized_validation_data.npz
│   │   ├── train_log_1k.txt
│   │   └── train_log.txt
│   └── scripts/
├── kodlar
│   ├── preprocessing.py
│   ├── predict.py
│   └── save_train_data.py
├── verileri çekme
│   └── test_training_args.py
├── aracı
│   ├── test.py
│   └── train.py
├── main.py
├── servisi
│   ├── README.md
│   └── .gitignore
└── edilmeyecek dosyalar
```

Ham veri dosyaları
1000 örnekten oluşan eğitim
200 örnekten oluşan test verisi
Doğrulama verisi
1K veriyle eğitilmiş model
10K veriyle eğitilmiş model
Eğitim ve test çıktıları
1K eğitim parametreleri
10K eğitim parametreleri
1K ROUGE test sonuçları
10K ROUGE test sonuçları
Tokenize 1K veri
Tokenize eğitim verisi (10K)
Tokenize doğrulama verisi
1K eğitim logları
10K eğitim logları
Tüm işlem adımlarını içeren
Metin ön işleme ve etiketleme
Eğitilen modelle özet üretme
datasets kütüphanesinden
Eğitim parametrelerini doğrulama
ROUGE skorları ile test işlemi
model eğitimi
FastAPI tabanlı inference
Proje hakkında genel açıklamalar
Git versiyon kontrolüne dahil

8. Sonuç

Model, sınırlı veriyle eğitilmesine rağmen çıktıları anlamlı ve tutarlıdır. ROUGE-1 ve ROUGE-Lsum skorları, kelime ölçeğinde yeterli kapsama sağladığını, ROUGE-2 skorları ise dil içi ardışık anlam bütünlüğünde hala geliştirilmeye açık noktalar olduğunu göstermektedir.

Hazırlayanlar:

- İlayda Arzu Akkuş
- Ece Sude Günerhan

GitHub: [GYK-NLP-Odev](#)